FIUBA

7506 - ORGANIZACIÓN DE DATOS

Fine Food Reviews

Author:
Mauro Toscano(96890)
Patricio Iribarne
Catella(96619)
Axel Lijdens (95772)

Supervisor:

Predecir el puntaje de los reviews en funcion de sus datos

in the

21 de noviembre de 2016

Índice general

List of Abbreviations

DF	**D**ata **F**rame
DTM	**D**ocument **T**erm **M**atrix
CV	**C**ross **V**alidation
CNN	**C**onvolutional **N**eural **N**etworks
RNN	**R**ecurrent **N**eural **N**etworks

Capítulo 1

Introducción

1.1. Análisis de los datos

El trabajo consiste en desarrollar un algoritmo que permita predecir el puntaje (1-5) que un usuario otorgó a un producto en base a su review (título, texto, etc).

Para ello, vamos a hacer enfoque en el campo del "sentiment analysis", que consiste en poder interpretar las emociones plasmadas en el texto.

Comenzamos utilizando algoritmos simples que nos permitieran hacer un análisis rápido de los datos, con el fin de poder estimar qué tipos de algoritmos funcionan mejor, cómo preprocesar el texto de forma que los resultados mejoren, etc.

1.1.1. Preprocesamiento del set de entrenamiento

Comenzamos por divir el set de entrenamiento en 3 partes:

- train: consiste en un 80 % del set original. Es utilizado para entrenar los algoritmos.
- cv: consiste en un 10 % del set original. Es utilizado para ajustar los hiper parámetros de los algoritmos y reducir el overfitting al set de entrenamiento.
- test: consiste en el 10 % restante. Utilizado para evaluar el desempeño final del algoritmo.

De esta forma podemos tener una estimación confiable sobre los resultados obtenidos sin necesidad de hacer varios submits a Kaggle.

1.1.2. Preprocesamiento de los campos

Cada review contiene una serie de campos con información sobre el mismo:

- Id - El id que identifica a cada review
- ProductId - El Id del producto
- UserId - El Id del usuario
- ProfileName - El nombre del usuario
- HelpfulnessNumerator - El numerador indicando la cantidad de usuarios que juzgaron al review como util

- HelpfulnessDenominator - El denominador indicando la cantidad de usuarios que evaluaron si el review fue útil o no
- Prediction - La cantidad de estrellas del review
- Time - Un timestamp para el review
- Summary - Un resumen del review
- Text - Texto del review

Encontramos que exceptuando Text y Summary, poco aportan los otros campos (y algunas veces hasta entorpecen el aprendizaje).

1.2. Sentiment analysis

Los puntajes otorgados a cada review se basan en que tan satisfechos estuvieron los usuarios con el producto, por lo que los comentarios deberían expresar cuál fue el sentimiento (alegría, enojo, frustración, etc) al recibirlo.

Es por esto que consideramos que la finalidad de TP es, basicamente, hacer un sentiment analysis, y luego mapear los sentimientos al valor del review.

En el sentiment analysis el preprocesamiento del texto juega un rol muy importante para la gran mayoría de los algoritmos **importance_of_preprocessing**

El primer paso es la tokenización, que consiste en separar el texto en palabras u otros símbolos que puedan aparecer (URLs, emoticones, puntos, comas, tags HTML, etc) **mining_twitter_data**

Los emoticones son de suma importancia, por lo que, para evitar perderlos y poder interpretarlos mejor, se pueden reemplazar por alguna palabra, por ejemplo:

- :), :-) ->smile
- :(->sad

Un paso bastante común, es remover las llamadas “stop words”, que son palabras muy comunes en los textos, y por lo general no aportan mucho al significado general de la oración **stopwords**

Además, para facilitar el reconocimiento de las palabras, es útil realizar un proceso conocido como stemming. En éste, se busca unificar todas las palabras que tengan un mismo origen o raíz. Esto si bien nos hace perder información, también nos permite generalizar más facilmente.

Por ejemplo, si un cliente hablara de cómo llega su producto, quizás se refiera en estos reviews a la palabra “shipping”. O quizás hable de que el barco llegó lento y mencione “ship”. Si bien son distintas, tienen una raíz que podría ser “ship”. Lo mismo sucede con conjugaciones de verbos. Si alguien menciona que disfrutó la comida puede usar cualquier tiempo verbal. “Enjoy” “Enjoyed” “Enjoying”, y carece de sentido tratar cada palabra por separado. Los sexos en sustantivos, y otras formas lingüisticas también llevan a otros arboles de palabras, que todas refieren al mismo concepto, o a la misma raíz.

Es interesantes marcar que la raíz que usemos para agrupar, no tiene por qué ser necesariamente una palabra. Esto es útil porque en la práctica permite simplificar los algoritmos de stemming. **word_stemming**

1.3. Expandiendo el set de datos

Por lo general, obtener más datos ayuda a mejorar el desempeño del algoritmo. Si bien no es trivial generar texto o modificar ejemplos para obtener nuevos, al considerar el problema como sentiment analysis podemos utilizar algún set de datos que tenga frases o palabras con un sentimiento asociado y entrenar un algoritmo para que lo aprenda a detectar.

Luego, otro algoritmo puede interpretar esos sentimientos y transformarlos en un valor 1-5. De esta forma podemos aprovechar una cantidad mayor de datos, agregando un paso intermedio. **lexicons_db**

Capítulo 2

Desarrollo

2.1. Algoritmos usados

Para comenzar, se decidió hacer uso de algoritmos simples y ver el resultado obtenido para poder compararlos y decidir cuál de todos profundizar.

Las pruebas se realizaron con los subsets obtenidos de dividir el set original, como se explicó en la introducción.

2.1.1. KNN

Uno de los primeros algoritmos a evaluar fue KNN. Para calcular las distancias, se decidió encodear los textos en un DTM utilizando una biblioteca de R **dtm_for_sentiment_analysis**

Previa a la creación de la matriz, se hizo una limpieza del texto, removiendo stop-words, puntuaciones HTML, etc.

Se comenzó probando con una porción muy pqueña del set (5 %), y se incrementó el tamaño en las pruebas subsiguientes.

Al llegar a aproximadamente un 15 % del set, el algoritmo era demasiado lento para clasificar (algunas horas), y no daba buenos resultados, por lo que se decidió probar otra alternativa.

Probablemente se pueda implementar mas adelante utilizando doc2vec, lo que debería reducir las dimensiones de los textos, y además dar resultados más precisos debido a la natureleza de los vectores generados (más similares al ser más parecidos).

2.1.2. Random forest

Este algritmo se comportó bastante mejor que KNN, ya que su tiempo de entrenamiento/clasificación era muy inferior, pero los resultados no fueron demasido buenos para predecir calificaciones menores a 3.

Si bien la idea fue tomada de **random_forest_movie_reviews** se convirtieron los textos a un bag of words y luego se la utilizó para entrenar el forest.

Se puede analizar más adelante aplicar una técnica similar a la del artículo citado.

Capítulo 3

Otras ideas

3.1. Motivación

Algunas ideas que no se llegaron a implementar, pero que se van a probar mas adelante, son mezcla de algoritmos que se encontraron en internet o papers, y que dieron buenos resultados.

Algunos son un poco complejos de implementar bien (o ajustar), por lo que se irán investigando de a poco.

3.1.1. NN

Teniendo en cienta que lo que buscamos es "transformar" el sentimiento del usuario en una puntuación, se podría aplicar algún algoritmo que transforme oraciones o palabras en una interpretación de sentimientos, por ejemplo

la peor experiencia de mi vida 0 -5 0 0 0 2

siendo los numeros negativos cuando el sentimiento es negativo, y positivo de otra forma.

Luego una red neuronal podría interpretar luego las combinaciones de dichos sentimientos y obtener un valor final.

3.1.2. CNN

Una posible solución seria utilizar CNN. La razón es que debido al uso de feature maps, podrían lograr una buena interpretación de las palabras en sus contextos y aprender ciertos patrones que derivan expresan el puntaje que otorgaría el usuario, sin importar la ubicación de los mismos en el texto.

El único problema sería lidiar con una cantidad de entradas variable (cada texto tiene un largo) distinto. Algunas opciones para esto son:

- tomar el texto mas largo del set de entrenamiento y utilizarlo como valor máximo (y luego paddear los textos mas cortos y recortar los mas largos)
- hacer "wrap around"
- utilizar alguna herramienta como "Doc2Vec" para convertir los textos a vectores. **doc2vec**

Los textos se pueden ingresar a la red en forma de bytes (caracter por caracter) o en alguna representación distinta, por ejemplo, vectores obtenidos por "word2vec", una conversión mas simple de valores que indican el sentiemiento de cada palabra, etc. **CNN_for_nlp**

3.1.3. RNN

Las RNN tienen la ventaja de poder trabajar con entradas de tamaño variable, y poder recordar contextos de manera más inteligente que las CNN. Es por esto que se va a intentar probar de implementar una para realizar el sentiment analysis. **LSTM_sentiment_analysis**

3.2. Conclusiones

Si bien hay varias ideas para aplicar, la más prometedora de acuerdo a lo investigado es una RNN, aunque la implementación y entrenamiento suelen ser no triviales.

La idea sería aplicar un preprocesamiento del texto para facilitarle el aprendizaje. Incluso se podría convertir el texto a un conjunto de vectores (utilizando word2vec), el cuál seria previamente preprocesado y evaluar los cambios en la prescisión.

Capítulo 4

Modelo con LSTM

4.1. Herramientas

Para desarrollar la implementación con LSTM se utilizó el framework en python llamado Keras, que implementa abstracciones sencillas para crear modelos de redes con distintas capas, utilizando Tensorflow o Theano.

Si bien permite realizar desarrollos y pruebas de forma rápida, no tiene el nivel de ajuste tan bajo nivel como utilizar directamente Theano o Tensorflow.

Todos los modelos fueron entrenados monitoreando el MSE (y la precisión en los modelos por clasificación), al mismo tiempo que se verificaba el "desempeño" en el set de cross-validation para controlar el overfitting.

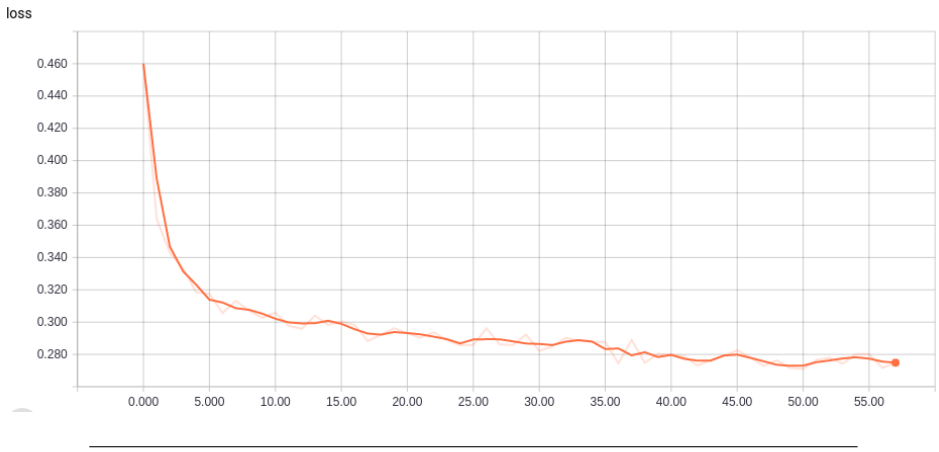

FIGURA 4.1: El valor del costo en el entrenamiento.

4.1.1. Limpieza del texto

Como la cantidad de términos era enorme (alrededor de 100.000), realizamos un checkeo manual sobre los textos, viendo que había varias URLs, HTML, fechas, horas, comillas, etc. Esto resultaba en una gran cantidad de tokens que realmente no aportaban demasiado, pero incrementaban el tamaño de los vectores encodeados, y por lo tanto se decidió hacer una limpieza del texto.

Las URLs fueron removidas, asi como también el HTML y los separadores como "———". Las fechas y horas fueron reemplazadas por las palabras "date" y "time" respectivamente, así como los números por la palabra "number". Las repeticiones del signo "$" o los montos "$nnn" fueron reemplazados por la palabra "money".

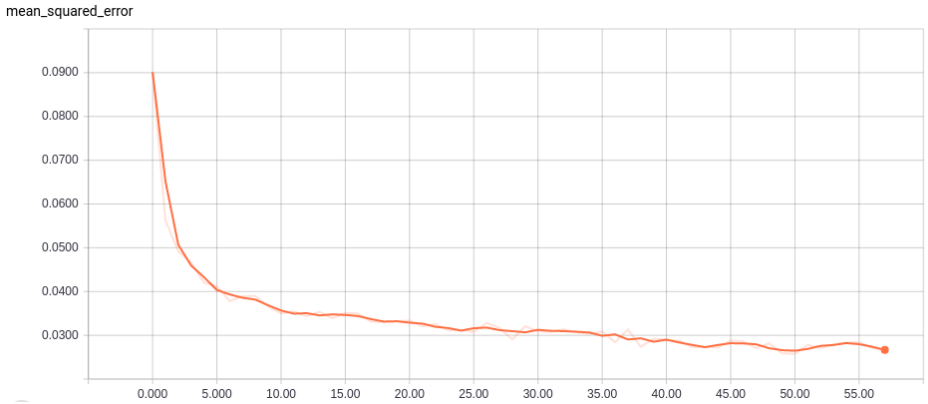

FIGURA 4.2: El valor del MSE en el set de entrenamiento.

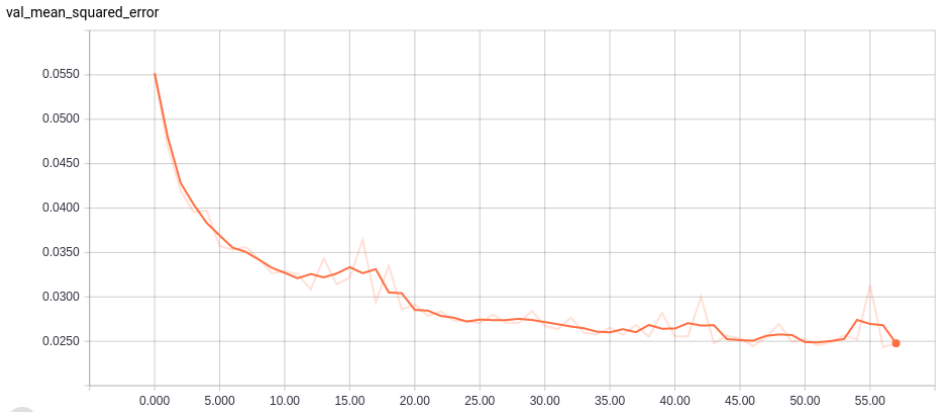

FIGURA 4.3: El valor del MSE en el set de CV luego de cada iteración.

También se removieron las comillas alrededor de las citas, para evitar tokens del tipo " 'this ".

Otras pruebas rápidas llevaron a concluir que el texto en el campo 'Summary' algunas veces resultaba útil, por lo que se decidió incluirlo también como parte del texto. Se experimentó utilizando configuraciones de redes y entrenandolas con los sets que incluian o ignoraban los summaries. Por lo general el resultado era mejor cuando se los inclyó.

4.2. LSTM con 1-hot encoding

Las redes LSTM mantienen un estado interno ("memoria") lo que permite, a diferencia de las otras, que la salida dependa no solo de la entrada, sino también de las entradas anteriores **understanding_LSTM** La forma de entrenarlas que utilizamos fue de a una palabra (encodeada en un vector) a la vez. Luego de analizar un review, el estado interno es reseteado. **LSTM_time_series_predictions stateful_LSTM**

En todos los casos, se utilizó entrenemiento por mini-batches para acelerar el proceso. Debido a esto, hubo que seleccionar un valor fijo de términos por review.

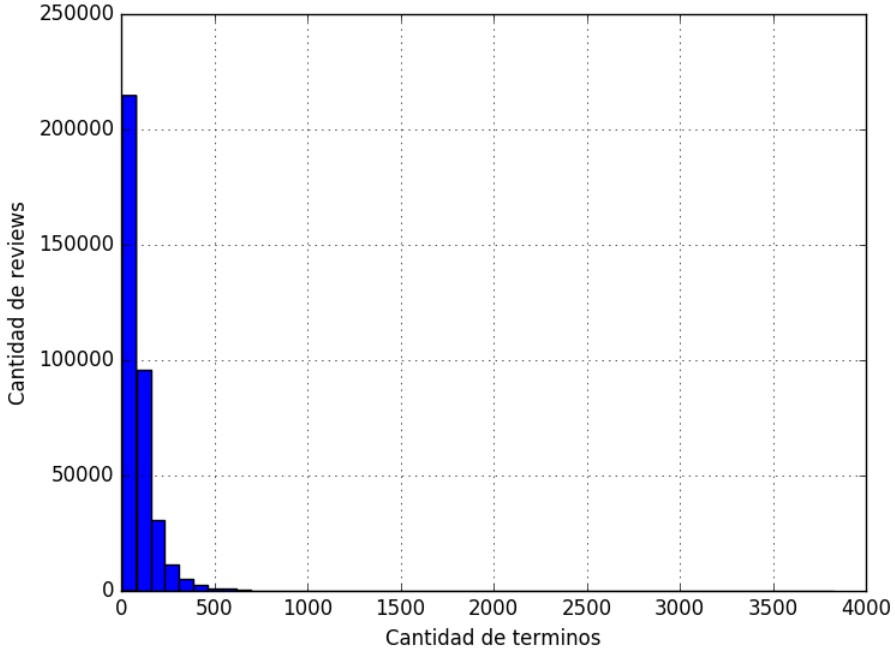

FIGURA 4.4: Histograma del largo de los reviews (por términos).

Debido a la cantidad de memoria requerida, no se pudo utilizar el largo mas grande (3826), por lo que decidimos elegir 400, que abarcaba la gran mayoria. Los reviews de mayor longitud fueron truncados, y los mas cortos paddeados con ceros al principio.

La primera prueba fue un modelo básico que consisía simplemente en 1 capa de 60 neuronas LSTM, recibiendo las palabras en un 1-hot encoding, ignorando stop words. Este modelo tenía 1 neurona con función de activación sigmoidal como salida para obtener un resultado en el rango 0-1.

El modelo logró un buen resultado para su simpleza (alrededor de 0.7 MSE en pruebas locales con el set de cross-validation).

Agregando una capa más de 60 neuronas LSTM, el MSE mejoró alrededor de un 0.1.

Paralelamente, los modelos equivalentes de clasificación (esto es, reemplazando la salida sigmoidal por 5 neuronas softmax) daban resultados un poco peores. Es por esto que decidimos enfocarnos más en los modelos de regresión, ya que los tiempos de entrenamiento eran de varias horas.

4.2.1. Aplicando capas convolucionales

Como las palabras cambian su sentido en base al contexto, por lo general suele ser mejor aplicar modelos de N-gramas.

Las redes convolucionales funcionan de manera similar, detectando patrones utilizando feature maps. De esta forma, la red puede "leer" de a varias palabras, teniendo en cuenta el contexto de las mismas **text_classification_using_CNN**

El siguiente modelo consistió en agregar una capa convolucional con una de maxpooling como entrada de la red. Como los resultados no mejoraron, probamos agregar varias capas con distintos tamaños de filtros. Los resultados en este caso fueron levemente mejores, e incluso en Kaggle el score fue de 0.4 aproximadamente.

4.3. Word2vec

La siguiente prueba fue analizar si utilizando word2vec se podría lograr una mejora en el algoritmo **w2v_text_classification**

La idea de utilizar word2vec es que las palabras con significados similares están asociadas a vectores cercanos, o que operaciones entre los mismos (suma, resta) resulta en vectores con cierto sentido. Idealmente, si una palabra no fue vista en el set de entrenamiento pero en un sinónimo de alguna que estaba presente, la red debería poder reconocerla igual.

Utilizando el modelo de word2vec de Google **word2vec_google** como entrada a la red, se obtuvo una leve mejora, aunque no fue fácil experimentar con los hiper-parámetros debido a los largos tiempos de entrenamiento de la red (16 hs aproximadamente).

El modelo final consistió en 3 capas convolucionales, con filtros de tamaño 4, 5 y 6, yendo a una capa de maxpooling, luego otra convolucional (esta vez con menos filtros), luego una capa LSTM y finalmente se combinaron esas 3 capas mediante otra de LSTM (con la salida sigmoidal o softmax).

4.4. Análisis de los resultados

Observando los resultados de las clasificaciones en el set de pruebas, se notó que la red tenía problemas para diferenciar reviews de 4 y 5 estrellas, así como los de 1 y 2.

A modo de ejemplo se muestra el siguiente caso:

> "delicious ! i love scharffen berger chocolate and this bar is no exception . the flavor is rich and deep . if you don't like coffee , it has a strong presence , though not masking the dark chocolate itself . this is a great snack on its own , and good in desserts as well . i recommend it ! "

La red predijo un score de 4.86 estrellas, lo cual resulta razonable, ya que no hay ninguna crítica negativa al respecto del producto pero el valor real de era de 4.

Este tipo de casos es dificil de diferenciar incluso para un humano, pero para varios casos, la red predijo un valores muy cercanos al verdadero, como por ejemplo de 4.95 contra un valor de 5 estrellas. Una posibilidad para mitigar esos pequeños errores es redondear los valores en los cuales la predicción es casi un entero. El método resultó inefectivo, ya que los errores se reducían tanto como se agrandaban.

Una alternativa fue entrenar un modelo clasificador, que otorga valores enteros como respuesta. Si la diferencia entre ambas predicciones era menor a un cierto umbral, entonces el valor de la regresión se reemplazaba por el de la clasificaión.

Este último método tampoco resultó efectivo, incluso para distintos valores de umbrales.

4.4.1. Balanceo del set de datos

Muchas veces la red tenía problemas para diferenciar los resultados de entre 1 y 3 estrellas. Como la distribución de las reviews en el set de datos es bastante irregular (una cantidad enormemente mayor de reviews de 5 estrellas frente a las demás) se probó como alternativa entrenar un modelo con el set de datos balanceado.

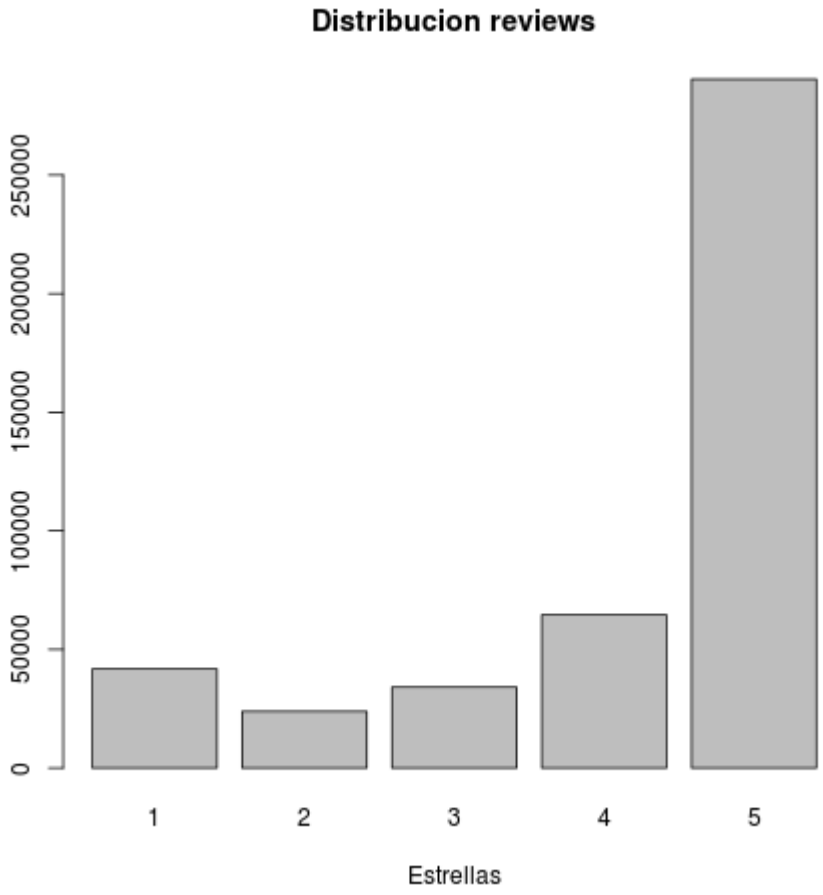

FIGURA 4.5: Distribución de reviews con respecto a las clases.

La metodología fue la siguiente:

- Dividir los reviews de 5 estrellas en fracciones
- Por cada una de las fracciones
    - Mezclarla con los demás reviews de 1-4 estrellas y entrenar la red con dicho set

De esta forma se esperaba favorecer el aprendizaje sobre los reviews de valores menos frecuentes, aunque los resultados mostraron que no hacían una gran diferencia (en ningún caso hubo siquiera una mejora).

Capítulo 5

Modelo solo con RNN

5.1. Primeros pasos

Para estas pruebas, se utilizo en todo momento una red neural recurrente, proporcionada por el paquete NNET, para el lenguaje R.

Se comenzo realizando un pre procesado de los textos, como se había hablado en un inicio, en el cual se sacaron stopwords, se hizo un proceso de stemming y se dejo todo en un formato de texto plano.

Las primer idea, fue entrenar la red neuronal con una DTM TF, sin embargo, esto se vio rapidamente inviable.

La DTM completa poseía cerca de 10000 terminos, que no era un problema almacenarlos mientras pudieramos usar un formato de matriz hecho para matrices dispersas, sin embargo, para entrenar la red, se necesitaba una matriz en su formato tradicional.

El primer cambio realizado fue el mas trivial, quitar terminos cuya ocurrencia sea muy baja. Asi, se sacaron los terminos que aparecían con una frecuencia menor a 1 cada 100 documentos y nos quedamos con aproximadamente 667 terminos.

Aún con esta cantidad, se tuvieron problemas de memoria, y la primer red neuronal fue entrenada con la mitad del set original, y utilizando un 80 % de los datos como train, y el resto como set.

El resultado fue cerca de un 14 % de precisión, la red neuronal no predecía.

5.2. Primeras correcciones

El error fue bastante evidente luego, nunca habíamos normalizado los datos. Decidimos entonces usar la normalización mas intuitiva. Aplicamos a todas las columnas la siguiente función:

$$z = \frac{x_i - min(x)}{max(x) - min(x)} \tag{5.1}$$

Los resultados fueron igual de malos.

Entonces probamos otra una normalización gausseana, muchas veces llamada estandarización:

$$z = \frac{x_i - \mu(x)}{\sigma(x)} \tag{5.2}$$

Y los resultados por primera vez fueron razonables. Redondeando los datos en el test se tuvo cerca de un 52 % de aciertos.

5.3. Preparando para kaggle

Para poder subir a Kaggle, necesitamos que nuestra red pueda predecir el test que tenemos. Sin embargo, se debe realizar la misma transformación a los datos que se le realizo al train. Para esto podíamos guardar los terminos y los datos de la media y el desvio estandar de cada de matriz, luego en el test quedarnos con esos terminos, y aplicar esa normalización. Siendo que solo nos interesa predecir un test, se decidio aprovechar para hacer todo esto, con el test y el train combinado.

Habiendo terminado eso, se subio la primer entrega a kaggle con un 1.15939 de error cuadrático medio.

5.4. SVD

Entrenar una red neuronal con una neurona, de la forma que veníamos haciendo era muy lento, y ocupaba mucho espacio en memoria. Por lo cual se decidio armar una SVD y quedarnos con los autovectores mas importante de la matriz u.

El primer inconveniente con esta idea, es que calcular la SVD, para la matriz DTM, excede nuestro poder computacional. Aún tirando terminos que se usan poco al principio. Si bien los métodos convenciales permiten cálcular menos vectores de U y de V, cálculan todos los autovalores. Y ahi se vuelve imposible

Se recurrio entonces a otro algoritmo conocido como IRLBA, augmented implicitly restarted Lanczos bidiagonalization algorithm. Este nos permite cálcular nuestra SVD con la cantidad de autovectores y autovalores que necesitemos. Es extremedamente rápido para buscar los autovalroes mas grandes y sus autovectores asociados. Aunque es mas lento si se quiere computar toda la SVD, pero como eso nos era imposible, trabajamos con este método.

También posee la ventaja de poder reanudarse. Utilizando el resultado de la ultima iteración, se puede seguir calculando mas autovalores y autovectores de la SVD, por lo cual no se pierde el trabajo computado.

Cálculamos 170 autovectores y autovalores, con una noche completa de cálculo. Lo primero que hicimos fue ver como era la distribución de la energía, para ver cuanta información perderíamos al estimar con la SVD. Este fue el resultado:

Lamentablemente, es una ley de potencias. La cola alargada que vemos, nos provoca que la energía comience a bajar muy de a poco. Y teniendo en cuenta que hay muchisimos terminos, el peso no es despreciable.

Aún así, siendo que de todas formas no podíamos utilizar todos los datos que teníamos, decidimos utilizar 50 columnas de la matriz u de la SVD para estimar los datos, y ver que sucede.

La velocidad a la que se entrena una red neuronal, y en consecuencia la cantidad de neuronas que podíamos utilizar, aumento considerablemente. Los resultados fueron un poco peores. Con una neurona y una capa, tal como fue el primero, se obtuvo en kaggle 1.32583 de RMSE. Recordamos que el original había sido 1.13817.

Sin embargo, aprovechando los nuevos tiempos de entrenamiento, se probo que pasaba si variabamos hiper parametros.

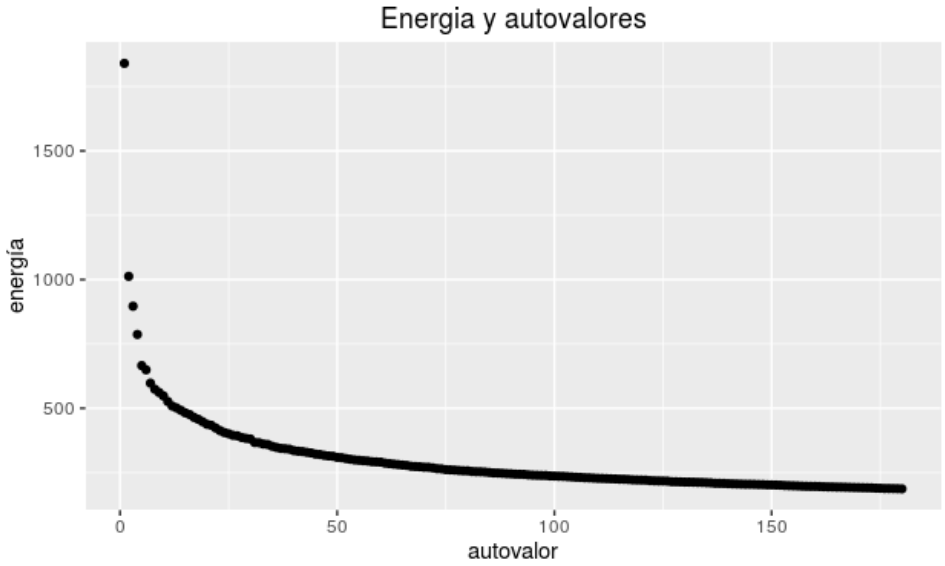

Si lo ponemos en escala logaritmica

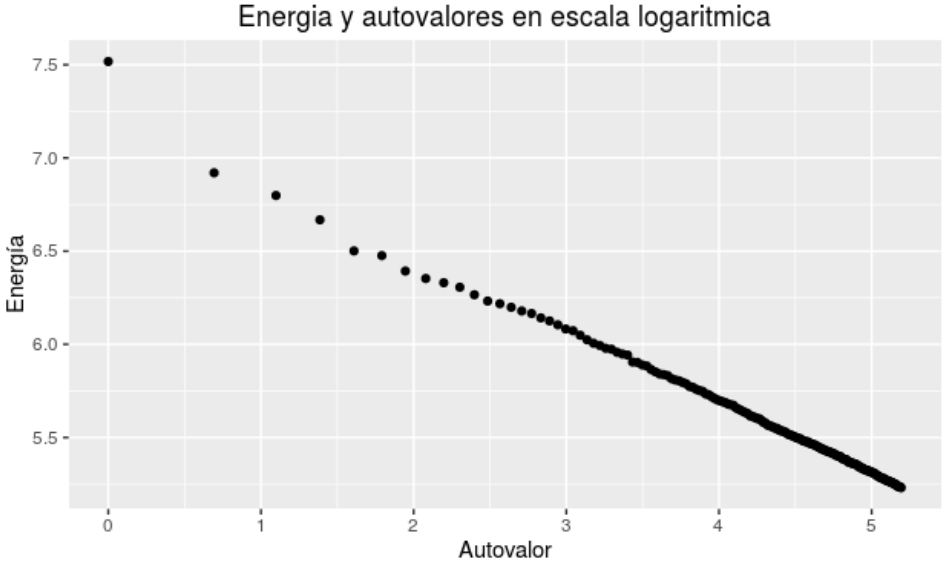

5.5. Ajustando hiper parametrós

Una primer prueba, solo por curiosidad, fue ver si había alguna diferencia cambiando de TF a IDF.

La red neuronal se entreno ligeramente mas rápido con IDF, y el resultado teniendo en cuenta la precisión fue:

TF - Precision en el Train: 55.3775 % TF - Precision en el Test: 54.78959 %

TF-IDF - Precision en el Train: 55.37 % TF-IDF - Precision en el Test: 54.72912 %

El cambio fue minimo. Se continuo usando TF que fue ligeramente superior.

Pasadas nuestras pequeñas pruebas, se planteo que había que automatizar la forma de ajustar hiper parametros. Y realizar una comparación mejor, que redondear los resultados.

Para esto utilizamos la librería Caret, y con ella, continuamos utilizando el mismo modelo. Ahora entrenamos con un two fold cross validation, y comparando con el error cuadratico medio. Trabajamos con una capa, y variamos la cantidad de neuronas y el decay. Para generar redes mas rápido, utilizamos una muestra del set. Al final entrenaremos con todo el set.

Elegimos two fold cross validation, porque si bien aumentamos la velocidad a la que calculamos una red neuronal, sigue sin ser despreciable el tiempo utilizado, mas cuando ahora la empezamos a complejizar. Por otro lado, configuramos el sistema para que compute distintas redes en diferentes nucleos y acelerar el proceso. También redujimos a un 20 % el set de entrenamiento, para poder computar más rápidamente las redes.

Este fue el primer resultado:

decay	size	RMSE	Rsquared
0.000	1	1.164061	0.2123402
0.000	2	1.144628	0.2383667
0.000	10	1.145871	0.2401054
0.001	1	1.153106	0.2270361
0.001	2	1.155142	0.2251961
0.001	10	1.131491	0.2577052
0.010	1	1.152959	0.2272637
0.010	2	1.135215	0.2507921
0.010	10	1.131509	0.2572446

Vemos que a medida que cuando aumenta la cantidad de neuronas el resultado en general mejora. Por otro lado, tener un poco de decay ayuda. Si bien el mejor resultado lo obtuvimos con un decay de 0.001, es en el caso de un decay de 0.01 donde siempre mejora el resultado, para todo tamaño de red. Y los valores son similares.

Agregamos entonces dos pruebas mas, con mas neuronas, y observamos que empeoro.

decay	size	RMSE	Rsquared
0.01	20	1.136187	0.2557508
0.01	50	1.171565	0.2322588

Entrenando conla muestra el resultado en kaggle fue de un RMSE de 1.26806. Y al entrenar con todo el train disponible llegamos a 1.20078. Un resultado que se empieza a acercar al primero.